



CENTRO UNIVERSITÁRIO SENAC
CURSO: ESPECIALIZAÇÃO EM INTELIGÊNCIA ARTIFICIAL

**DETECÇÃO DE INDÍCIOS DEPRESSIVOS EM TEXTOS UTILIZANDO
INTELIGÊNCIA ARTIFICIAL E PROCESSAMENTO DE LINGUAGEM NATURAL**

Edjan Gomes de Souza
Felipe Eduardo Sarti Mol
Laércio Costa
Marcos Manhanes de Souza
Natacha Castellão Ramos
Vinícius de Sousa Oliveira

São Paulo
2026

**DETECÇÃO DE INDÍCIOS DEPRESSIVOS EM TEXTOS UTILIZANDO
INTELIGÊNCIA ARTIFICIAL E PROCESSAMENTO DE LINGUAGEM NATURAL**

Documentação técnica apresentada como
requisito da disciplina Redes Neurais
Artificiais, referente ao Desafio 2 —
Análise de Perfil de Candidato com NLP.

Área: Processamento de Linguagem
Natural, Inteligência Artificial, Engenharia
de Software.

Sumário	
RESUMO.....	4
1 INTRODUÇÃO	5
2 FUNDAMENTAÇÃO TEÓRICA.....	5
2.2 Processamento de Linguagem Natural	6
2.3 Redes Neurais Artificiais	6
3 METODOLOGIA.....	7
4 DESENVOLVIMENTO E DESAFIOS DO PROJETO	7
5 RESULTADOS E DISCUSSÕES	9
6 CONCLUSÃO.....	9
REFERÊNCIAS	11

RESUMO

O crescimento do uso das redes sociais transformou as plataformas digitais em espaços de expressão emocional, permitindo que sentimentos, comportamentos e estados psicológicos sejam compartilhados diariamente por milhões de pessoas. Nesse contexto, técnicas de Inteligência Artificial e Processamento de Linguagem Natural vêm sendo utilizadas para identificar padrões linguísticos associados a transtornos emocionais e psicológicos. O presente artigo apresenta o desenvolvimento de um modelo computacional voltado para a identificação de possíveis indícios depressivos em publicações da plataforma X (Twitter), utilizando Redes Neurais e técnicas de PLN. O projeto foi desenvolvido em ambiente Google Colab, utilizando Python, TensorFlow e bibliotecas de apoio para manipulação e análise dos dados. Durante o desenvolvimento, foram enfrentadas dificuldades relacionadas à limpeza textual, escolha de métricas adequadas, entendimento das arquiteturas neurais e controle de overfitting. Os resultados demonstraram que o modelo conseguiu identificar padrões relevantes em textos curtos, atingindo resultados satisfatórios para um projeto acadêmico introdutório. Além do desenvolvimento técnico, o trabalho também proporcionou reflexões sobre os desafios éticos envolvidos na utilização da Inteligência Artificial aplicada à saúde mental.

Palavras-chave: Inteligência Artificial. Processamento de Linguagem Natural. Redes Neurais. Depressão. Machine Learning.

1 INTRODUÇÃO

A saúde mental tornou-se uma das principais preocupações da sociedade contemporânea. O aumento de casos relacionados à ansiedade, depressão e transtornos emocionais tem impulsionado pesquisas voltadas para ferramentas tecnológicas capazes de auxiliar na identificação precoce desses problemas. Paralelamente, o crescimento das redes sociais fez com que plataformas digitais passassem a registrar sentimentos, emoções e comportamentos humanos em grande escala.

Nesse cenário, a Inteligência Artificial (IA) surge como uma importante aliada no desenvolvimento de sistemas capazes de interpretar padrões linguísticos presentes em textos produzidos pelos usuários. Técnicas de Processamento de Linguagem Natural (PLN) permitem que computadores interpretem palavras, contextos e relações semânticas, tornando possível identificar padrões emocionais associados a possíveis transtornos psicológicos.

O presente trabalho tem como objetivo desenvolver um modelo computacional para identificação de possíveis indícios depressivos em tweets, utilizando técnicas de Machine Learning e Redes Neurais. O projeto foi desenvolvido utilizando um conjunto de dados obtido na plataforma Kaggle, contendo publicações textuais classificadas entre depressivas e não depressivas.

Além dos aspectos técnicos, o desenvolvimento do projeto também proporcionou importantes aprendizados relacionados à interpretação de métricas, tratamento de dados textuais e compreensão das dificuldades práticas existentes na construção de modelos de Inteligência Artificial aplicados a problemas reais.

2 FUNDAMENTAÇÃO TEÓRICA

2.1 Inteligência Artificial e Machine Learning

A Inteligência Artificial consiste no desenvolvimento de sistemas capazes de executar tarefas que normalmente exigiriam inteligência humana, como reconhecimento de padrões, tomada de decisão e interpretação de linguagem. Dentro desse contexto, o Machine Learning possibilita que algoritmos aprendam

padrões a partir dos dados sem a necessidade de programação explícita para cada situação.

Os algoritmos de aprendizado supervisionado utilizam exemplos previamente classificados para aprender relações entre entradas e saídas. No caso deste projeto, o modelo foi treinado para identificar padrões textuais associados à variável de saída relacionada à presença ou ausência de indícios depressivos.

2.2 Processamento de Linguagem Natural

O Processamento de Linguagem Natural é uma área da Inteligência Artificial voltada para a interpretação computacional da linguagem humana. Seu principal objetivo é permitir que máquinas consigam compreender textos, identificar significados e extrair informações relevantes.

Em aplicações relacionadas à saúde mental, o PLN possibilita identificar padrões emocionais presentes em textos escritos espontaneamente pelos usuários. Palavras associadas à tristeza, vazio emocional, desesperança e isolamento podem ser utilizadas como indicadores importantes durante o treinamento do modelo.

2.3 Redes Neurais Artificiais

As Redes Neurais Artificiais são estruturas matemáticas inspiradas no funcionamento do cérebro humano. Elas são compostas por neurônios artificiais interligados, capazes de aprender padrões complexos a partir dos dados.

Neste projeto, foram utilizadas técnicas envolvendo Embeddings e Redes Neurais voltadas para análise textual. Os Embeddings permitem transformar palavras em representações numéricas densas, preservando relações semânticas entre os termos. Dessa forma, palavras emocionalmente semelhantes passam a ocupar posições próximas no espaço vetorial.

Também foram utilizadas técnicas de regularização e prevenção de overfitting, buscando garantir que o modelo não apenas memorizasse os dados de treino, mas fosse capaz de generalizar corretamente para novos exemplos.

3 METODOLOGIA

O desenvolvimento do projeto foi realizado utilizando a linguagem Python em ambiente Google Colab. Foram utilizadas bibliotecas como Pandas, NumPy, TensorFlow, Keras e Scikit-Learn para manipulação, treinamento e avaliação do modelo.

O conjunto de dados utilizado foi composto por tweets classificados entre depressivos e não depressivos. Inicialmente, realizou-se a limpeza textual utilizando expressões regulares (Regex), removendo links, hashtags, menções, caracteres especiais e espaços desnecessários.

Após a limpeza, os dados foram divididos em conjuntos de treino e teste, utilizando aproximadamente 80% das amostras para treinamento e 20% para validação do modelo. Essa separação foi importante para evitar que o algoritmo apenas decorasse os exemplos apresentados.

Na etapa de tokenização, as palavras foram convertidas em identificadores numéricos, permitindo o processamento computacional do texto. Posteriormente, aplicou-se o processo de padding para padronização do tamanho das entradas textuais.

A arquitetura desenvolvida utilizou camadas de Embedding para representação semântica das palavras, seguidas por camadas neurais responsáveis pela identificação dos padrões emocionais presentes nos textos. Também foram utilizadas técnicas como Dropout e Early Stopping para redução do overfitting e melhora da generalização do modelo.

A função de perda utilizada foi a Binary Crossentropy, escolhida por apresentar melhor desempenho em problemas de classificação binária. Durante o desenvolvimento, percebeu-se que métricas como Recall e F1-Score eram mais relevantes do que apenas a acurácia geral, principalmente devido ao contexto sensível envolvendo saúde mental.

4 DESENVOLVIMENTO E DESAFIOS DO PROJETO

Durante o desenvolvimento do projeto, diversas dificuldades foram encontradas pelo grupo, principalmente relacionadas à compreensão do comportamento das redes neurais e das métricas de avaliação.

Inicialmente, houve dificuldade para compreender como os textos poderiam ser interpretados matematicamente pela Inteligência Artificial. O entendimento sobre tokenização, embeddings e processamento vetorial exigiu estudos complementares além do conteúdo apresentado em aula.

Outra dificuldade importante esteve relacionada à limpeza dos dados textuais. As primeiras execuções apresentavam baixo desempenho devido à presença excessiva de ruídos, como links, hashtags, emojis e caracteres especiais. A partir disso, tornou-se necessário implementar uma etapa mais rigorosa de pré-processamento textual.

Também surgiram desafios relacionados ao overfitting. Em algumas execuções, o modelo apresentava ótimo desempenho nos dados de treino, mas falhava significativamente nos dados de validação. Isso levou o grupo a estudar técnicas como Dropout, Early Stopping e regularização.

Além das dificuldades técnicas, o projeto também despertou reflexões importantes sobre responsabilidade ética. Durante o desenvolvimento, o grupo compreendeu que a Inteligência Artificial não deve substituir profissionais da saúde, mas atuar como ferramenta auxiliar de apoio à triagem computacional.

Outro aprendizado importante ocorreu durante a interpretação das métricas de avaliação. Inicialmente, acreditava-se que a acurácia seria suficiente para validar o modelo. Entretanto, ao aprofundar os estudos, percebeu-se que métricas como Recall e F1-Score eram fundamentais para avaliar corretamente sistemas voltados à identificação de possíveis riscos emocionais.

O desenvolvimento do projeto também contribuiu significativamente para o amadurecimento técnico do grupo. Conceitos que inicialmente pareciam extremamente abstratos, como embeddings, redes neurais e gradiente descendente, passaram a ser compreendidos de maneira mais prática ao longo das implementações.

5 RESULTADOS E DISCUSSÕES

Os resultados obtidos demonstraram que o modelo conseguiu identificar padrões relevantes nos textos analisados. A utilização de embeddings permitiu melhorar significativamente a representação semântica das palavras, enquanto as camadas neurais auxiliaram na identificação de padrões emocionais presentes nos tweets.

As métricas obtidas indicaram desempenho satisfatório para um projeto acadêmico introdutório, especialmente considerando a complexidade existente em tarefas de análise emocional textual. O modelo apresentou equilíbrio entre precisão e sensibilidade, demonstrando capacidade razoável de generalização.

A análise da matriz de confusão permitiu compreender melhor os tipos de erro cometidos pelo modelo, evidenciando a importância da interpretação detalhada das previsões realizadas pela Inteligência Artificial.

Também foi possível perceber que o desempenho do modelo depende fortemente da qualidade dos dados utilizados no treinamento. Pequenas alterações no pré-processamento textual influenciaram diretamente os resultados obtidos.

6 CONCLUSÃO

O presente trabalho possibilitou compreender, na prática, os desafios envolvidos no desenvolvimento de sistemas de Inteligência Artificial aplicados ao Processamento de Linguagem Natural. Além dos aspectos técnicos, o projeto também proporcionou reflexões importantes sobre ética, responsabilidade computacional e limitações dos modelos preditivos.

O desenvolvimento permitiu aprofundar conhecimentos relacionados à manipulação de dados textuais, tokenização, embeddings, redes neurais e métricas de classificação. Também evidenciou a importância da preparação adequada dos dados para obtenção de resultados consistentes.

Embora o modelo tenha apresentado resultados satisfatórios, existem diversas possibilidades de melhoria futura, como utilização de arquiteturas mais

modernas baseadas em Transformers e modelos pré-treinados especializados em linguagem natural.

Por fim, conclui-se que a Inteligência Artificial possui grande potencial para auxiliar processos de análise emocional e triagem computacional, desde que utilizada de forma ética, supervisionada e complementar à atuação humana.

REFERÊNCIAS

GOODFELLOW, Ian; BENGIO, Yoshua; COURVILLE, Aaron. Deep Learning. Cambridge: MIT Press, 2016.

RUSSELL, Stuart; NORVIG, Peter. Artificial Intelligence: A Modern Approach. 4. ed. Pearson, 2021.

JURAFSKY, Daniel; MARTIN, James H. Speech and Language Processing. 3. ed. Pearson, 2023.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, v. 12, p. 2825–2830, 2011.

CHOLLET, François. Deep Learning with Python. 2. ed. Manning Publications, 2021.

TensorFlow Documentation. Disponível em: <https://www.tensorflow.org/>. Acesso em: 28 maio 2026.

Kaggle Dataset – Mental Health Twitter Dataset. Disponível em: <https://www.kaggle.com/>. Acesso em: 28 maio 2026.